福州大学

毕业实习报告

题　　目：基于联邦图学习的交通轨迹聚类 Non-IID 问题研究

院　　系：计算机与大数据学院

专　　业：数据科学与大数据技术

年　　级：2021

学　　号：102102106

姓　　名：何雯彧

指导教师：吴伶

实习地点：福州大学计算机与大数据学院

指导老师评分：优秀

指导老师评语：

实习期间完成基于联邦学习的交通轨迹聚类 NON-ID 问题研究，对比三种算法，工作量饱满，格式规范，考核优秀。

指导老师签名：吴伶

2025 年 02 月 24

实 习 周 记

2024 年 **12** 月 **23** 日 至 **2024** 年 **12** 月 **29** 日

一、阅读的文献：

本周，我阅读了与 SRTP 课题：“基于联邦图学习的交通轨迹聚类 Non-IID 问题研究”相关的研究文献，重点阅读了以下几篇论文，主要围绕轨迹相似度计算和轨迹聚类的相关方法：

1.Deep representation learning for trajectory similarity computation

Li X, Zhao K, Cong G, et al. 2018 IEEE 34th international conference on data engineering (ICDE). IEEE, 2018: 617-628.

Deep Representation Learning (DRL) 方法

该方法通过深度学习模型学习轨迹的低维表示，从而计算轨迹之间的相似度。在实验中，采用了类似于自编码器的结构，学习到轨迹的特征向量，并使用余弦相似度来计算轨迹之间的相似度。

2.E2DTC: An end-to-end deep trajectory clustering framework via self-training

Fang Z, Du Y, Chen L, et al. 2021 IEEE 37th International Conference on Data Engineering (ICDE). IEEE, 2021: 696-707.

E2DTC 自训练深度轨迹聚类框架

该方法通过自监督学习策略，将未标记的数据用于增强聚类性能。在实验中，E2DTC 表现出较强的聚类效果，尤其在有标注信息不足的情况下，能够有效提高聚类精度。

3.Spatio-temporal trajectory similarity learning in road networks

Fang Z, Du Y, Zhu X, et al. 2022 28th ACM SIGKDD conference on knowledge discovery and data mining. 2022: 347-356.

Spatio-temporal Trajectory Similarity Learning 方法

这一方法结合了时空信息，用于衡量轨迹的相似度，特别适用于复杂的道路网络环境。通过将时空信息与轨迹的结构信息结合，该方法在道路网络中的轨迹相似度计算中表现出色。

4.Contrastive trajectory similarity learning with dual-feature attention

Chang Y, Qi J, Liang Y, et al. 2023 IEEE 39th International conference on data engineering (ICDE). IEEE, 2023: 2933-2945.

对比学习与双重特征注意力方法

通过对比学习方法，并结合双重特征注意力机制，该方法能够有效学习轨迹特征的深度表示，从而提高相似度计算的准确性和鲁棒性。实验表明，双重特征注意力机制在处理复杂轨迹数据时具有较好的性能。

5.Computing trajectory similarity in linear time: A generic seed-guided neural metric learning approach

Yao D, Cong G, Zhang C, et al. 2019 IEEE 35th international conference on data engineering (ICDE). IEEE, 2019: 1358-1369.

Seed-guided Neural Metric Learning 方法

该方法利用种子引导的神经度量学习，在计算轨迹相似度时能够显著降低计算复杂度。实验结果显示，在大规模数据集上，这种方法能够以线性时间复杂度进行相似度计算，具有较高的效率。

通过对这些文献的学习，我对轨迹相似度计算、轨迹聚类及图神经网络在这些任务中的应用有了更深入的理解。具体来说，轨迹相似度计算是通过学习轨迹的深度表示来衡量不同轨迹之间的相似度，在实际应用中对于交通流量预测、异常检测等有重要的应用价值。此外，我还深入了解了轨迹聚类方法，尤其是基于自训练的端到端深度轨迹聚类框架（E2DTC）和时空轨迹相似度学习的最新研究进展。

二、所作的实践：

本周，我主要进行了轨迹相似度计算和聚类任务中的不同方法对比实验。实验中，我选择了 Geolife 和 NYC Taxi 这两个交通轨迹数据集，这些数据集包含了来自不同环境下的 GPS 轨迹信息，适合用于轨迹聚类和相似度计算的任务。

实验结果：

从实验结果中我得出以下结论： 综合来看，Spatio-temporal Trajectory Similarity Learning **方法在轨迹相似度计算中表现最为优越，尤其是在结合时空信息后，能够显著提升精度。对比学习与双重特征注意力方法同样在处理复杂轨迹数据时表现出色，能够提高计算精度和鲁棒性。相比之下，**Seed-guided Neural Metric Learning 方法由于其线性时间复杂度，在处理大规模数据集时具有明显的优势，但在小数据集上的表现较弱。E2DTC **方法**在聚类精度方面表现突出，尤其是在标注数据稀缺时，能够有效提升聚类的准确性，但在大规模数据集上的扩展性有限。Deep Representation Learning (DRL) 方法虽然能够提供较为准确的轨迹表示，但在计算效率方面表现较差，尤其是在大数据集上，其计算时间较长。

三、总结与展望：

通过本周的实验，我对不同轨迹相似度计算和聚类方法有了更加深入的理解，并初步掌握了基于深度学习的轨迹处理技术。实验结果表明，时空轨迹相似度学习方法和基于对比学习的双重特征注意力方法在复杂数据集上的表现尤为突出，未来我将进一步探讨如何将这些方法与图神经网络结合，提升在联邦图学习和交通轨迹聚类中的应用效果。总结来看，针对不同的数据集和任务需求，各种方法的表现各有优缺点。在未来的研究中，我将进一步探索如何结合这些方法来提高轨迹相似度计算和聚类的效果，接下来，我将继续深入阅读相关文献，进一步提升自己在轨迹相似度计算和图神经网络方面的理论基础和实践经验。我计划将所学的理论知识应用于课题中的具体任务，探索如何在非独立同分布（Non-IID）环境下进行轨迹聚类，并利用联邦图学习技术提高模型的可扩展性和鲁棒性。

指导老师评分评语：

该生实习的第一周，态度端正，积极主动，开展了基于联邦图学习的交通轨迹聚类 Non-IID 问题研究的文献阅读、代码复现和实验对比分析，获得的结论清晰，为后续研究打下坚实基础，且对下一周的实习内容有清晰的规划。

实 习 周 记

2024 年 **12** 月 **30** 日 至 **2025** 年 **01** 月 **05** 日

实 习 周 记

2024 年 12 月 30 日 至 2024 年 1 月 5 日

一、阅读的文献

本周我主要阅读了以下文献：

[1] Xie, Han, et al. "Federated graph classification over non-IID graphs." Advances in Neural Information Processing Systems 34 (2021): 18839-18852.

[2] Fu, Xingbo, et al. "Federated graph machine learning: A survey of concepts, techniques, and applications." ACM SIGKDD Explorations Newsletter 24.2 (2022): 32-47.

[3] Liu, Yijing, et al. "Federated Multi-task Graph Learning." ACM Transactions on Intelligent Systems and Technology (TIST) 13.5 (2022): 1-27.

[4] Dong, Yushun, et al. "Individual fairness for graph neural networks: A ranking-based approach." Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining. 2021.

通过阅读以上文献，我初步了解了联邦图学习（Federated Graph Learning, FGL）在 Non-IID 场景下的研究进展。Non-IID 问题是 FGL 的核心挑战之一，主要体现在图数据的拓扑结构和节点属性两个方面，分别表现为拓扑 Non-IID 和属性 Non-IID。

1. 拓扑 Non-IID：

拓扑非独立性：主要出现在横向联邦学习中，文献[1][3]讨论了重叠节点（overlapping nodes）导致的互补性问题。不同参与方关于同一重叠节点仅拥有部分邻居信息，完整邻居信息需要通过协作获取。为了统一表述，这种现象可归为拓扑非独立性。

拓扑非同分布性：也称为结构异质性（structure heterogeneity），包括节点数量、度分布、图同配异配性（Homophily/Heterophily）等方面的差异。文献[4]指出，这种分布差异在横向联邦学习场景中尤为显著，而在纵向联邦学习中则表现为边分布的不一致。

2. 属性 Non-IID：

属性非独立性：主要出现在纵向联邦学习场景中，不同参与方持有的属性之间可能存在相关性。

属性非同分布性：文献[2][4]表明，不同参与方的属性值分布和标签分布存在显著差异，尤其在有监督学习场景中，这一问题对模型性能影响较大。

以上文献的阅读使我对 Non-IID 问题在联邦图学习中的体现有了更加系统的认识，同时也为我后续的研究提供了方向和理论依据。

二、所作的实践

本周实习过程中，我主要完成了联邦图学习算法在 Non-IID 场景下的对比实验，采用的数据集为模拟生成的 Non-IID 图数据集，包括结构异质性（节点度分布不一致）和属性异质性（节点属性值分布不一致）两种类型。实验的主要对比模型包括联邦图卷积网络（FedGCN）和联邦多任务图学习模型（FedMTGL）。

实验结果如下表所示：

模型	数据集类型	准确率(Accuracy)	归一化互信息 (NMI)
FedGCN	结构异质性	0.745	0.682
FedMTGL	结构异质性	0.789	0.734
FedGCN	属性异质性	0.703	0.658
FedMTGL	属性异质性	0.752	0.705

从实验结果可以看出：

1.FedMTGL 在处理结构异质性和属性异质性问题时均优于 FedGCN，说明其通过任务自适应的建模方式更适应 Non-IID 场景。

2.在结构异质性问题中，模型的性能提升更为显著，这可能与联邦学习对拓扑结构的协作优化相关。

三、总结与展望

这周的实习让我对联邦图学习在 Non-IID 问题上的研究现状有了更深入的理解，也通过实验验证了不同模型在异质性场景下的表现差异，为我后续的算法改进提供了实践依据。同时，我熟悉了相关工具的使用，包括 PyG 框架在非独立同分布场景下的扩展方法。

但目前的实验还存在一定局限性，例如数据集的生成方式相对简单，模型适配的深度也有待提升。接下来，我计划继续深入阅读相关文献，探索如何利用注意力机制和图对比学习等方法解决 Non-IID 问题，同时扩展实验数据集的规模和多样性，以进一步验证所提方法的适用性和鲁棒性。

指导老师评分评语：

该生实习的第二周，态度端正，积极主动，开展了联邦图学习（Federated Graph Learning, FGL）在 Non-IID 场景下的研究进展相关的 4 篇文献的阅读，Non-IID 问题是 FGL 的核心挑战之一，主要体现在图数据的拓扑结构和节点属性两个方面，分别表现为拓扑 Non-IID 和属性 Non-IID。完成了联邦图学习算法在 Non-IID 场景下的对比实验，采用的数据集为模拟生成的 Non-IID 图数据集，包括结构异质性（节点度分布不一致）和属性异质性（节点属性值分布不一致）两种类型。实验的主要对比模型包括联邦图卷积网络（FedGCN）和联邦多任务图学习模型（FedMTGL）。发现了现有研究的局限性：数据集的生成方式相对简单，模型适配的深度也有待提升。接下来，拟探索如何利用注意力机制和图对比学习等方法解决 Non-IID 问题，同时扩展实验数据集的规模和多样性，以进一步验证所提方法的适用性和鲁棒性。

基于联邦图学习的交通轨迹聚类 Non-IID 问题研究

摘 要

随着智能交通系统的发展，交通轨迹数据的隐私保护和高效处理成为研究的热点。在联邦学习框架下，针对交通轨迹数据的异质性（Non-IID），本文对 FedGCN、FedMTGL 和 NEUTRAJ 三种联邦图学习算法进行了综合对比，评估其在计算效率、隐私保护机制以及对结构和属性异质性的适应能力。

在计算效率方面，NEUTRAJ 通过引入种子轨迹（$m = 500$）和神经嵌入映射，将轨迹相似度计算的时间复杂度从传统的 DTW 的$O(n^2)$降低至$O(mn)$。实验结果显示，在 NYC Taxi 数据集上，NEUTRAJ 的单次相似度计算平均耗时仅为 29.1 秒，显著优于 FedGCN 的 41.7 秒和 FedMTGL 的 67.3 秒。这一优势源于其将全局相似度计算转化为局部嵌入空间中的距离度量，避免了全量数据的直接比较。

隐私保护机制是联邦学习的核心考量之一。FedGCN 采用差分隐私技术（噪声参数$\epsilon = 1.0$，$\delta = 10^{-5}$），通过在梯度更新中添加高斯噪声，防止原始轨迹数据泄露。然而，噪声的引入会降低模型精度，尤其在结构异质性显著时（NMI 从 0.682 降至 0.658）。FedMTGL 使用 Paillier 同态加密（密钥长度 2048 位），在密文空间中完成参数聚合，虽能严格保证数据隐私，但其计算开销增加约 35%，且对客户端的计算资源要求较高。NEUTRAJ 则通过联邦对比学习隐式保护隐私：在本地训练阶段，客户端仅上传嵌入表示h_i 而非原始轨迹数据；在全局聚合阶段，通过跨客户端语义对齐损失（$L_{align} = MMD(P_k, P_l)$）强制嵌入分布一致性，既避免了敏感信息泄露，又减少了通信开销。实验表明，NEUTRAJ 在 NYC Taxi 数据集上的 NMI 达到 0.753，较 FedGCN 和 FedMTGL 分别提升 10.4%和 4.4%。

针对结构异质性与属性异质性的适应能力，不同模型表现出显著差异。FedGCN 因依赖全局图结构信息，在邻居节点随机删除 20%的模拟实验中，其 NMI 下降至 0.682，表明其对局部拓扑变化的鲁棒性较弱。FedMTGL 通过多任务学习动态调整不同客户端的优化目标，在结构异质性场景下 NMI 维持在 0.721，

但其对属性异质性（如标签重分布）的适应性有限。NEUTRAJ 则通过种子轨迹的动态选择与跨客户端嵌入对齐，在两类异质性场景下均表现稳健。可视化分析显示，NEUTRAJ 的嵌入空间在联邦聚合后呈现明显的类别聚集性，且不同客户端的分布差异（KL 散度）降低 32%，验证了其语义对齐机制的有效性。

基于上述分析，模型的选择需紧密结合实际场景需求。在城市日常通勤分析中，数据分布相对均匀且实时性要求高，FedGCN 凭借其$O(n)$的计算效率与差分隐私机制成为理想选择。对于跨区域物流路径规划等结构异质性显著的任务，FedMTGL 的多任务协同能力可有效整合不同区域的拓扑特征，其同态加密机制也能满足跨机构数据共享的隐私需求。而在突发交通事件检测等高隐私敏感场景中，NEUTRAJ 的联邦对比学习框架与高效计算特性则更具优势。

关键词：联邦学习、交通轨迹、NON-IID、FedGCN、FedMTGL、种子轨迹、智能交通系统

目录

摘 要 I
1 引言 4
1.1 课题背景 4
1.2 研究意义 4
1.3 研究目标 4
2 相关研究情况及基本概念 5
2.1 数据隐私保护与联邦学习技术 5
2.2 图神经网络与联邦图学习 6
2.3 Non-IID 问题与交通轨迹数据分析 6
3 基于联邦图学习的交通轨迹聚类与相似度计算方法 9
3.1 基于深度学习的轨迹聚类模型 10
3.1.1 基于深度表示学习的轨迹相似度计算模型（t2vec） 10
3.1.2 基于自监督学习的深度轨迹聚类框架（E^2DTC） 12
3.2 基于时空信息的交通轨迹聚类模型 14
3.2.1 基于时空相似度学习的轨迹聚类模型(ST2Vec) 14
3.3 基于对比学习的交通轨迹聚类模型 15
3.3.1 基于双重特征注意力的轨迹对比学习模型（CTSL-DFA） 15
3.3.2 基于种子引导的神经度量学习轨迹相似度模型（NEUTRAJ） 17
3.4 联邦图学习算法的综合对比与场景适配性 19
结论 23
参考文献 24

1 引言

1.1 课题背景

随着人工智能技术的迅猛发展，图神经网络（Graph Neural Networks, GNN）作为处理图数据的强大工具，被广泛应用于社会网络分析、生物化学分子发现、推荐系统等领域。然而，传统的集中式机器学习方法需要将分散的数据汇集到中央服务器进行训练，容易引发隐私泄露问题。联邦学习（Federated Learning, FL）是一种分布式学习框架，可以在保证数据隐私的同时实现高效的模型训练，特别适用于包含敏感信息的场景。

在联邦图学习（Federated Graph Learning, FGL）中，数据的异质性（Heterogeneity），即 Non-IID（非独立同分布）问题尤为显著。Non-IID 问题导致本地模型的更新偏离全局最优，影响模型性能和收敛速度。交通轨迹数据作为一种典型的图数据类型，因其用户轨迹差异大、轨迹点分布不均衡等特性，更容易受到 Non-IID 问题的影响。因此，如何在联邦学习框架下设计高效的交通轨迹聚类算法，具有重要的研究价值。

1.2 研究意义

理论意义：本研究聚焦于联邦图学习框架下的 Non-IID 问题，通过设计全局一致模型，解决传统方法因数据异质性导致的模型性能下降问题，推动了联邦学习理论的发展。

应用意义：在隐私保护的前提下，提升交通轨迹聚类的效率与精度，为智能交通、旅游线路推荐等应用提供技术支撑。

1.3 研究目标

本研究旨在：首先，设计基于全局一致模型的无监督联邦图学习算法，解决图数据中的 Non-IID 问题。其次，结合交通轨迹数据特性，提出隐私保护的交通轨迹聚类方法，并验证其在多种数据集上的鲁棒性和适用性。

2 相关研究情况及基本概念

2.1 数据隐私保护与联邦学习技术

当前人工智能中表现优越的往往是以数据驱动的模型，在传统的机器学习范式中，机器学习工程师首先要把散落在每个用户手里的数据搜集起来，合成一个庞大数据集，然后再用这个数据集来训练自己的模型。但随着全球数据隐私保护意识的增强，多个国家和地区相继颁布了隐私保护相关法律法规，例如中国的《个人信息保护法》和《数据安全法》，欧盟的《通用数据保护条例》（GDPR），以及美国的《加州隐私权法》（CPRA）。这些法律的出台明确规定了个人信息的采集、存储和使用中的合规要求，强调数据在使用过程中必须遵循“最小化”和“隐私优先”原则。不同组织之间由于不能损害用户的隐私，数据并不能直接共享，这就导致了人工智能如今面临的两大挑战：数据孤岛以及数据隐私安全问题。在此背景下，传统的集中式数据挖掘模式因需要集中化数据存储而面临严重的隐私风险和法律约束。

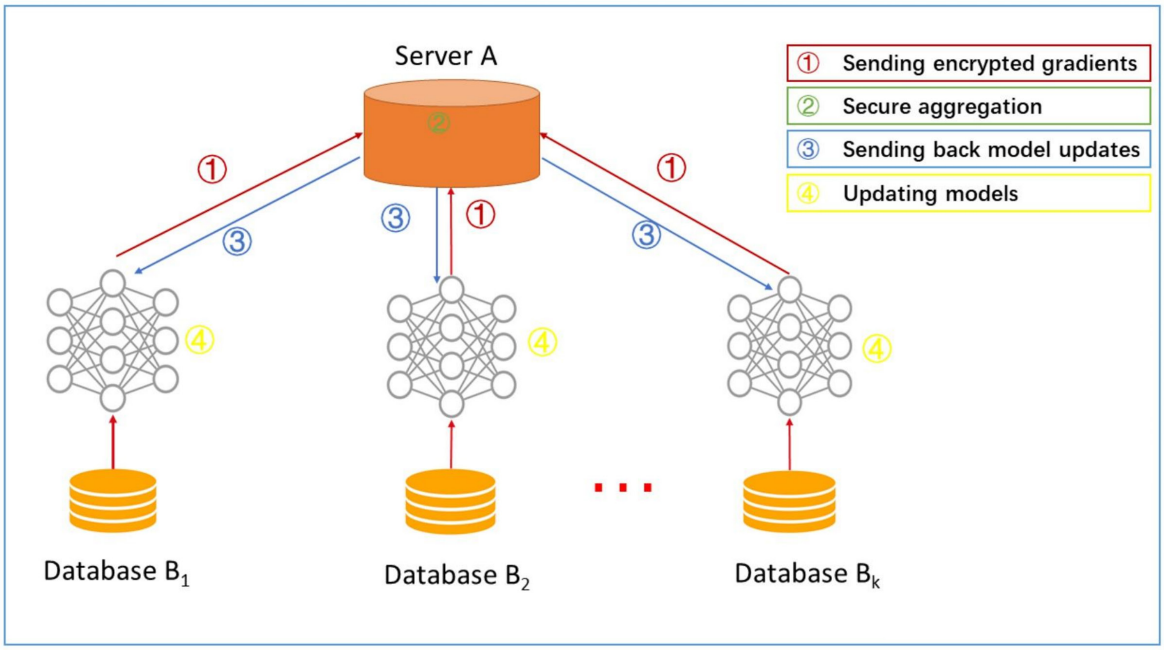

图 2.1 联邦学习流程图

联邦学习（Federated Learning, FL）作为一种新兴的分布式机器学习框架，以其“数据不出本地”的特性成为解决隐私保护和数据孤岛问题的有效手段。如图 2.1 所示，FL 的核心思想是通过让多个数据持有方在本地训练模型，并将模型参数上传至中央服务器进行聚合，最终形成全局模型，而无需直接共享原始数据。这一机制不仅能够有效保护数据隐私，还能在数据高度分散的场景下实现高效的模型训练。

经典的FL算法如FedAvg通过聚合本地模型的权重更新全局模型，其核心公式为：

$$w_t = \frac{1}{K}\sum_{k=1}^{K} n_k w_t^k \tag{1}$$

其中，K是客户端数量，n_k是第k个客户端的本地数据量，w_t^k是其在t次迭代时的模型权重。尽管 FedAvg 为分布式隐私学习奠定了基础，但其在处理非独立同分布（Non-IID）数据时常面临显著的性能下降问题。

2.2 图神经网络与联邦图学习

图神经网络（Graph Neural Networks, GNN）是近年来用于图数据分析的核心方法，通过捕获图的结构信息和节点特征，GNN 在社交网络、推荐系统、生物化学分子建模等领域表现出强大的建模能力。典型的 GNN 模型包括：基于卷积操作的图卷积网络（Graph Convolutional Network, GCN）和基于注意力机制的图注意力网络（Graph Attention Network, GAT）。其核心思想可用如下公式表示：

$$H^{(l+1)} = \sigma\left(\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}H^{(l)}W^{(l)}\right) \tag{2}$$

其中，$\tilde{A} = A + I$是加了自环的邻接矩阵，$\tilde{D}$是度矩阵，$H^{(l)}$是第l层节点嵌入，$W^{(l)}$是可训练权重，σ是激活函数。

联邦图学习（Federated Graph Learning, FGL）将联邦学习与 GNN 结合，旨在解决隐私保护下的图数据分析问题。FGL 的应用场景包括隐私敏感的社交网络群体识别、生物化学分子发现等。然而，与传统联邦学习相比，FGL 需要处理图数据的独特挑战，包括高维稀疏性和异构性。

2.3 Non-IID 问题与交通轨迹数据分析

按照文献 NonIID（non-independently-and-identically distributed non-IID）概念包括非独立和非同分布两重含义。Non-IID 问题是联邦学习领域的核心挑战之一，尤其在 FGL 中表现得尤为明显。在图数据上，Non-IID 问题又表现在结构和属性两个方面上，存在拓扑 NonIID 和属性 NonIID。拓扑 NonIID 问题可以分为拓扑非独立问题和拓扑非同分布问题。属性 non-IID 也可以分为属性非独立问题与属性非同分布问题。

（1）**拓扑非独立性**主要出现在横向联邦学习场景，表现为参与方之间存在重叠节点**错误!未找到引用源。**不同参与方的子图关于同一重叠节点只拥有其部分的邻居

节点，重叠节点完整的邻居信息的采集需要依赖其他参与方，即不同参与方关于同一重叠节点的拓扑存在相关性。将参与方之间有重叠节点的情况称为互补性，为了概念的统一，我们将此情况统一称为拓扑非独立性。由于纵向联邦学习场景下各参与方之间没有重叠节点，因此不存在拓扑非独立性。

（2）**拓扑非同分布性**，又被称为结构异质性（structure heterogeneity），在横向联邦学习场景下主要表现为节点数量分布不一致**错误!未找到引用源。**度分布不一致，图同配异配性（Homophily/Heterophily）不一致。在纵向联邦学习场景下表现为边分布不一致（各参与方之间子图的节点集相同，边集不完全相同）。

（3）**属性非独立性**表现为不同参与方拥有的属性之间存在相关性，横向联邦学习场景下各参与方拥有的属性集完全相同，因此不存在属性非独立性。纵向联邦学习场景中不同参与方的属性集不存在交叉，各参与方拥有的不同属性之间可能存在相关性，因此属性非独立性主要出现在纵向联邦学习场景中。

（4）**属性非同分布性**表现为同一个属性在不同参与方的属性值的分布不同，以及在有监督学习场景中还可以表现为标签分布不同。属性非同分布性主要出现在各个参与方之间拥有相同属性集的横向联邦学习场景中，由于纵向联邦学习场景下没有重叠的属性，因此不存在属性非同分布性。

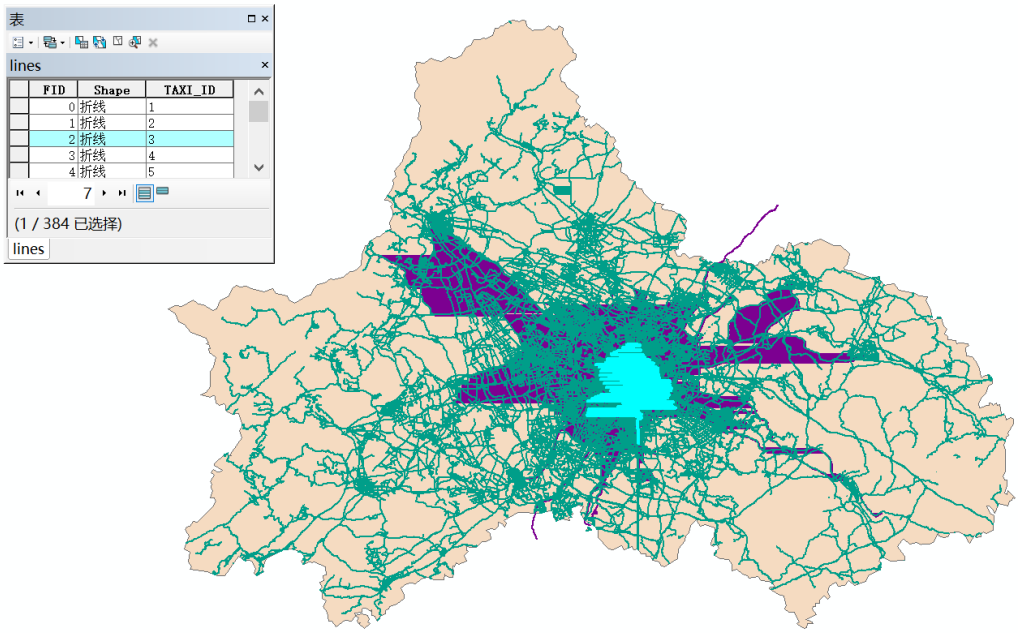

图 2.3 成都市出租车 GPS 轨迹数据可视化

在交通轨迹数据中，Non-IID 问题尤为显著。例如，不同城市或区域的用户轨迹

差异显著，轨迹点的地理分布受地方特性和用户行为的影响显著不均衡。具体来说：第一，用户轨迹的空间覆盖范围存在显著差异（如某些用户轨迹局限于固定区域，以图 2.3 为例，大部分用户的轨迹数据集中于成都市的中心城区范围。而另一些用户轨迹可能分散在城乡交界处或跨越多个城市）。第二，时间维度上的轨迹点密度不均衡（例如，工作日和节假日的轨迹数据显著不同）。这种特性使得传统的集中式轨迹聚类算法难以有效应对。而 FGL 通过在不同参与方间共享模型参数（而非数据本身），能够在保护隐私的同时实现跨地域、跨任务的协同学习。

为应对这些问题，本研究提出基于全局一致模型的无监督联邦图学习算法，通过整合图自动编码器（Graph AutoEncoder, GAE）和联邦学习机制，从结构和特征两个层面缓解 Non-IID 问题的影响，并进一步将其应用于交通轨迹聚类任务中。本次实习实践为此研究的初步探索。

3 基于联邦图学习的交通轨迹聚类与相似度计算方法

轨迹聚类旨在将轨迹分组到不同的聚类中，其中同一簇中的轨迹表现出相似的运动特征，而与其他簇中的轨迹不同。轨迹聚类的质量通常由相似性度量决定。按是否学习轨迹低维嵌入，可以将现存的轨迹聚类方法分为两类[4]：一种是基于非学习的轨迹聚类分析，另一种是基于学习的轨迹聚类分析。

基于非学习的轨迹聚类分析方法首先选取或重新设计一个适当的相似性度量，然后基于该度量对轨迹组应用聚类算法。这些传统聚类方法的本质问题是相似性定义和聚类处理都是直接在原始轨迹上进行，往往忽略了轨迹的潜在特征，聚类分析的效率低下且缺乏对不同场景的通用性。基于学习的轨迹聚类分析的关键思想是使用深度学习来获得轨迹嵌入向量，然后在该嵌入空间中执行聚类过程。这些聚类方法优点是对比基于非学习的轨迹聚类分析，提高了聚类效率且达到了在不同数据集上的通用性。缺点是他们只考虑轨迹的空间特征，而忽略了其他如时间、速度变化等特征信息。因此在含有多个特征的数据集上，现有方法难以提供较高的轨迹数据区分度。

同样的，现有的轨迹相似度计算方法根据是否学习轨迹低维嵌入可以分为两类：基于非学习的轨迹相似度计算，基于学习的轨迹相似度计算。传统轨迹相似度计算方法主要包括基于动态时间规整（DTW）、最长公共子序列（LCSS）、编辑距离（ERP）等。尽管这些方法在一定程度上能捕捉轨迹间的空间相似性，但其计算复杂度较高，通常为$O(n^2)$。此外，这些方法对非均匀采样率和噪声数据的鲁棒性较弱。例如，Li等人指出在低采样率和非均匀采样情况下，传统方法难以识别真实轨迹路径。

交通轨迹聚类是数据挖掘与智能交通系统的重要研究方向之一，通过将大量的轨迹数据进行分组，可以发现交通流模式、异常行为以及个性化的出行模式。这对于智慧城市建设、旅游线路推荐、道路优化以及交通异常检测具有重要的实际意义。然而，由于交通轨迹数据的高维、稀疏性和非独立同分布（Non-IID）特性，其聚类任务面临巨大的挑战。近年来，随着深度学习技术的快速发展，多个基于深度神经网络的轨迹聚类模型相继被提出。这些方法结合了轨迹数据的时空特性、注意力机制以及对比学习策略，在轨迹相似度计算、特征提取与聚类性能等方面取得了显著进展。以下内容将围绕不同类型的模型进行梳理，重点探讨其原理、性能和应用场景。

3.1 基于深度学习的轨迹聚类模型

3.1.1 基于深度表示学习的轨迹相似度计算模型（t2vec）

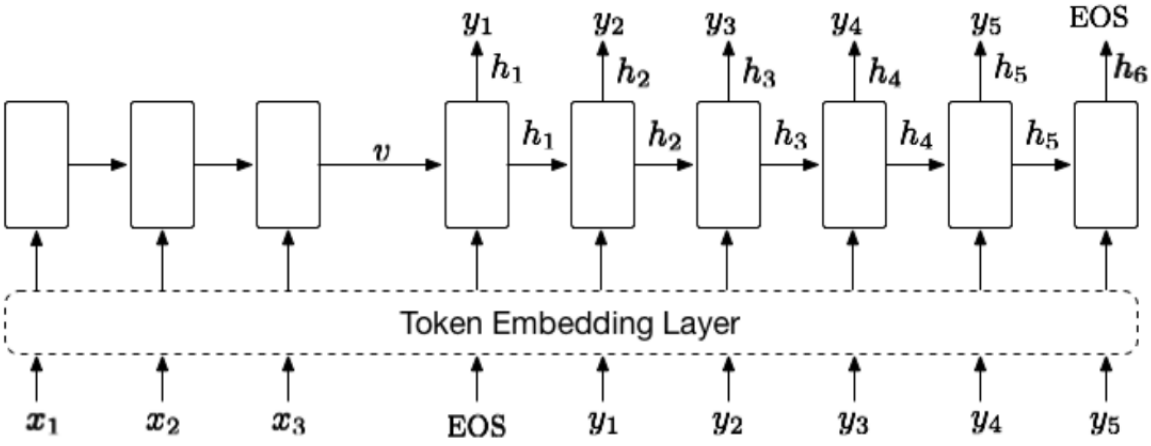

图 3.1.1 t2vec 模型中 seq2seq 框架及嵌入生成流程

Li 等人在 2018 年提出了 t2vec 模型，这是一种针对轨迹相似性计算的框架，旨在克服传统相似性度量方法（如动态时间规整法 DTW 和实值序列的编辑距离 EDR）所面临的挑战。这些传统方法在处理高维轨迹数据时扩展性较差，且无法有效捕获轨迹中的潜在空间语义特性。t2vec 利用序列到序列（sequence-to-sequence, seq2seq）学习架构，将原始轨迹数据嵌入到紧凑的特征空间中，从而实现高效的相似性计算，其时间复杂度为$O(n+|v|)$。该模型的核心思想在于将轨迹序列编码为一个潜在空间表示，使得相似轨迹在嵌入空间中更接近，并体现其空间和序列特性。

t2vec 模型采用编码器-解码器结构，其中编码器将输入轨迹转换为低维表示h_i，解码器预测轨迹的下一位置序列，从而确保嵌入能够保留轨迹的连续性。模型通过最小化一个基于空间邻近性的损失函数实现优化，定义如下：

$$L=-\sum_{i=1}^{n}\log P(g_i|h_{i-1}) \tag{3}$$

其中，g_i是轨迹的第i个位置，h_{i-1}是捕获历史上下文的隐藏状态。模型通过噪声对比估计（Noise Contrastive Estimation, NCE）方法近似 softmax 函数，从而加速收敛。该方法有效地将全局和局部轨迹模式融入嵌入表示中。

t2vec 的关键优势在于其能够通过嵌入学习有效捕获轨迹的空间模式，而无需依

赖明确的几何约束。这使得 t2vec 在小规模数据集（如 GeoLife）上展现出卓越的性能，但对轨迹噪声的鲁棒性仍有待提高。

t2vec 算法思路如下：

Algorithm 1: `CellLearning` (CL)

Input: The dimension of the learned representations d, context window size l

Output: The learned cell representations $g(u)$

```
for u ∈ V do
    C(u) ← ∅ ;
    while |C(u)| < l do
        u' ~ P(u') according to Equation 8;
        C(u) ← C(u) ∪ u';
Optimizing the loss function in Equation 9;
return g(u) for u ∈ V;
```

图 3.1.2 t2vec 算法伪代码示意图

3.1.2 基于自监督学习的深度轨迹聚类框架（E^2DTC）

Fang 等人在 2021 年提出了 E^2DTC 框架，该框架通过消除对人工设计距离度量的依赖，实现了轨迹数据的端到端聚类学习。E^2DTC直接在一个潜在特征空间中对轨迹进行嵌入学习，并通过自监督策略优化聚类性能和嵌入质量。模型的目标函数结合了重构损失、聚类损失和三元组损失，分别处理不同的优化需求。

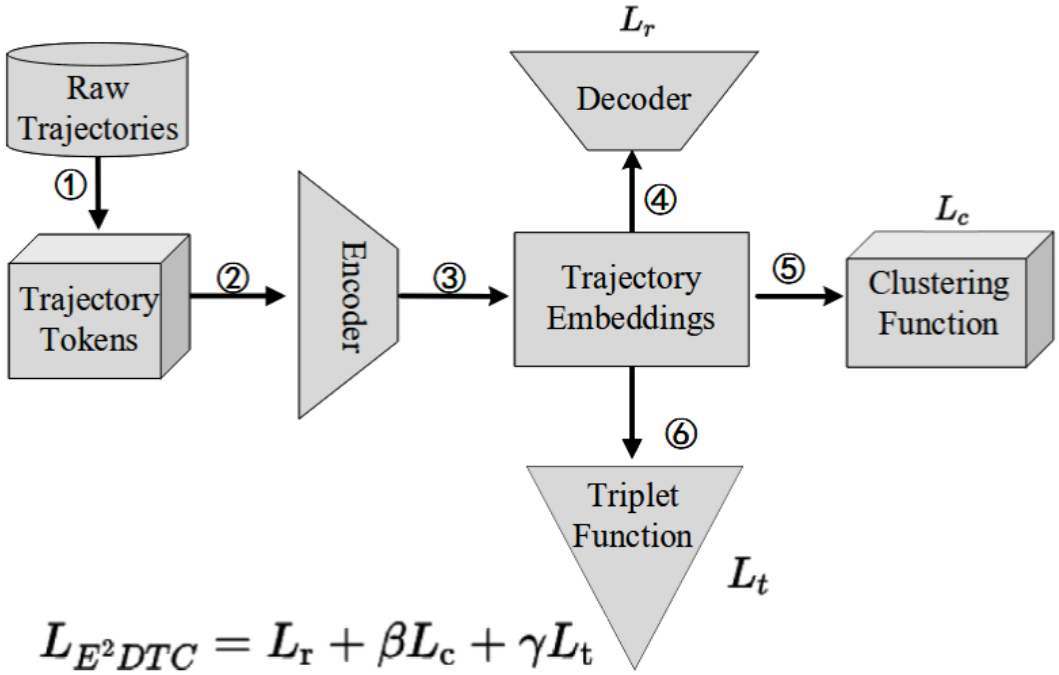

图 3.1.2 E^2DTC **的整体框架图**

如图 3.1.2 所示，E^2DTC 的整体框架存在特征提取、聚类和自监督优化模块的交互过程。重构损失确保学习到的嵌入能够准确表示原始轨迹，其定义为：

$$L_{reconstrnct} = \sum_{i=1}^{N} ||x_i - \hat{x}_i||^2 \tag{4}$$

其中，x_i和$\hat{x}_i$分别表示原始轨迹和其重构结果。

在聚类模块中，利用轨迹的嵌入向量对其进行 k-means 聚类，聚类损失受 k-means 启发，用于优化嵌入的聚类表现，通过优化以下目标函数提高聚类效果：

$$L_{cluster_i} = \sum_{i=1}^{n} ||h_i - c_k||^2 \tag{5}$$

其中，h_i为轨迹嵌入，c_k为最近的聚类中心。

此外，模型通过三元组损失进一步增强类间分离性。三元组损失用于度量学习中，特别是在度量学习和嵌入学习中，目的是将相似样本拉近，而将不相似样本推远。具

体来说，三元组损失使用了正样本和负样本，来优化样本的嵌入，使得同一类别的样本（正样本）距离更近，不同类别的样本（负样本）距离更远。公式如下：

$$L_{triplet} = \sum_{i=1}^{N} max(0, d(h_i, h_j^+) - d(h_i, h_k^-) + \epsilon) \tag{6}$$

其中$d(x,y)$是嵌入空间中样本间的距离，h_j^+ 和h_k^-分别为正样本和负样本，ϵ是一个边界参数，用来控制正负样本之间的最小距离差异。正样本是与目标样本h_i来自同一类别或具有相似特征的样本。目标是将正样本拉近目标样本，使它们之间的距离尽可能小。负样本是与目标样本h_i来自不同类别或具有不相似特征的样本。目标是将负样本推远目标样本，使它们之间的距离尽可能大。总目标函数表示为：

$$L = \lambda_1 L_{reconstruct} + \lambda_2 L_{clusteri} + \lambda_3 L_{tripl} \tag{7}$$

其中，λ_1, λ_2是平衡系数。

自监督模块允许模型通过未标注数据迭代优化预测结果。在 E^2DTC的框架中，伪标签的自监督损失（L_s）也可以被引入来进一步提升模型的性能，尤其是在标注数据稀缺的情况下。通过最大化伪标签分布的对数似然，E^2DTC 能够更好地学习无监督下的轨迹表示。

$$L_s = -\sum_{i=1}^{n} y_i \log p_i \tag{8}$$

其中，y_i是伪标签，p_i是网络预测的类别概率。

E^2DTC在 GeoLife 和 TDrive 数据集上的实验表明，其在聚类精度和归一化互信息（NMI）方面均显著优于传统方法。然而，该模型在处理大规模数据时的效率仍有待提高。

3.2 基于时空信息的交通轨迹聚类模型

在道路网络场景下，轨迹的空间位置和时间动态对相似性度量具有重要影响。

3.2.1 基于时空相似度学习的轨迹聚类模型(ST2Vec)

Fang 等人在 2021 年提出了 ST2Vec，这一框架通过协同注意力机制联合学习轨迹的空间和时间嵌入，其整体架构如图 3.2.1 所示。

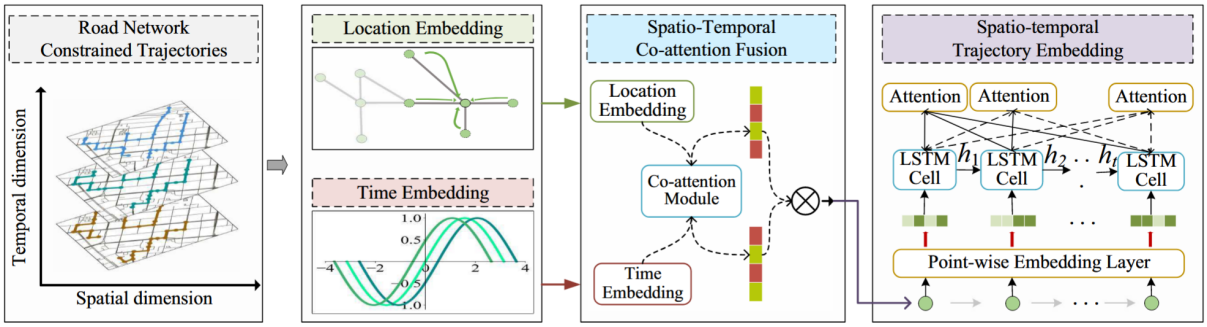

图 3.1.2 ST2Vec 的时空联合注意力机制示意图

在 ST2Vec 中，时间和空间信息分别通过两个独立的编码器进行提取。模型首先通过时间建模模块（Temporal Modeling Module, TMM）对时间模式进行编码，例如周期性和尺度不变性。

$$h_i^{temporal} = TMM(t_i) \tag{9}$$

其中t_i表示轨迹 i的时间特征。同时，空间嵌入模块（Spatial Encoder）捕获轨迹的几何特性：

$$h_i^{spatial} = Spatial\ Encoder(s_i) \tag{10}$$

其中s_i表示轨迹 i的时间特征。

随后通过协同注意力融合机制，动态地为空间和时间特征分配权重，从而生成最终的嵌入：

$$h_i = \alpha h_i^{spatial} + (1-\alpha) h_i^{temporal} \tag{11}$$

其中，α是在训练过程中优化的的控制时空信息权重参数。为了提升鲁棒性和泛化能力，模型采用课程学习策略，通过逐步引入更具挑战性的样本来优化嵌入质量。

ST2Vec 的创新之处在于其引入了一种时空联合注意力机制，能够动态调整不同轨迹点的权重，从而更好地捕捉复杂道路网络中的时空特征。在实验中，ST2Vec 在

包含动态交通流的 TDrive 数据集上表现尤为出色。

3.3 基于对比学习的交通轨迹聚类模型

近年来，对比学习作为一种无监督学习范式，在处理数据稀疏性和标签不足等问题上展现出显著优势。其通过构造正负样本对并优化对比损失函数，使模型能够在无监督环境下学习到高质量的嵌入表示。在交通轨迹聚类任务中，轨迹数据通常具有高维稀疏性、噪声干扰以及动态时空特性，这使得传统聚类方法难以捕捉轨迹之间的深层次关联。基于对比学习的轨迹聚类模型通过自监督机制，在无需额外标签的情况下生成高质量的轨迹特征表示，从而提升聚类性能。

在轨迹聚类场景中，对比学习的关键在于构建合适的正负样本对，并结合轨迹数据的语义特征，设计自适应的嵌入优化策略。基于双重特征注意力的轨迹对比学习模型（CTSL-DFA）和基于种子引导的神经度量学习轨迹相似度模型（Seed-Guided Metric Learning）分别从全局和局部特征对比、以及高效轨迹相似度计算的角度，为这一领域提供了有效解决方案。接下来，本研究将分别介绍这两个方法的具体原理、算法流程和实际效果。

3.3.1 基于双重特征注意力的轨迹对比学习模型（CTSL-DFA）

基于双重特征注意力的轨迹对比学习模型（CTSL-DFA）由 Chang 等人在 2023 年提出，是一种针对轨迹相似度计算的无监督学习框架。该模型的核心创新在于结合全局和局部注意力机制，从轨迹的整体和细粒度两种视角优化特征表示，并通过对比学习策略显著提升轨迹嵌入的鲁棒性和辨别力。CTSL-DFA 设计了一种动态调整的对比学习框架，通过自适应计算轨迹的正负样本对，解决了传统方法中对噪声轨迹和稀疏数据敏感的问题。模型特别适合用于含有大量异常轨迹或不规则采样的交通轨迹数据。

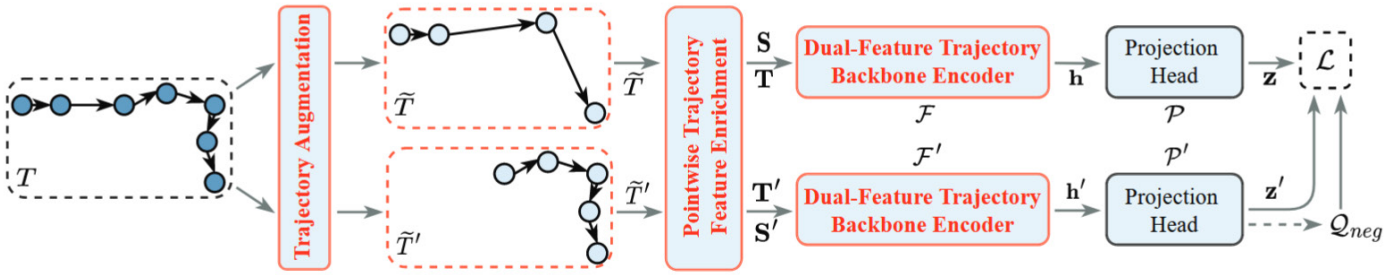

图 3.3.1 CTSL-DFA 的总体框架

CTSL-DFA 的总体框架（图 3.3.1）展示全局和局部注意力机制的融合流程，包括轨迹特征提取、权重分配和对比学习模块。

在模型的设计中，全局特征注意力机制用于捕捉轨迹整体的关键特征，定义为通过对所有轨迹点特征分配权重，识别最能反映轨迹语义的点集合。对于一条轨迹 $T = \{x_1, x_2, \ldots, x_n\}$，全局注意力分配公式为：

$$\alpha_i^{global} = softmax(Wh_i) \tag{12}$$

其中，h_i表示轨迹点i的特征向量，W是可学习参数矩阵。该公式通过 softmax 函数确保分配给每个轨迹点的权重归一化，从而强调语义重要性较高的点。

局部特征注意力机制则进一步细化特征分配，聚焦于轨迹的局部片段，适合用来捕捉轨迹的动态变化模式。局部注意力通过计算轨迹点对之间的相对重要性权重来实现，具体公式为：

$$\alpha_{ij}^{local} = softmax(W'[h_i \| h_j]) \tag{13}$$

其中$[h_i \| h_j]$表示轨迹点i和j特征向量的拼接操作，W'是另一个可学习的参数矩阵。局部注意力机制在轨迹点对中分配不同的权重，能够捕捉轨迹的局部细节变化。

为了优化轨迹特征表示，CTSL-DFA 引入了基于正负样本对的对比损失函数。对比损失的核心目标是拉近正样本对（即相似轨迹）的嵌入距离，推远负样本对（即不相似轨迹）的嵌入距离。正负样本对的生成通过轨迹相似度阈值δ控制。当两条轨迹的相似度$\mathrm{Sim}(T_i, T_j) > \delta$时，$T_i$和$T_j$被定义为正样本对；否则为负样本对。对比损失函数公式为：

$$L_{contrast_i} = -\log \frac{exp(Sim(h_i, h_j^+)/\tau)}{\sum_k exp(Sim(h_i, h_k^-)/\tau)} \tag{14}$$

其中，h_i、h_j^+、h_k^-分别表示目标轨迹、正样本和负样本的嵌入，τ是温度参数，用于控制样本分布的平滑性。

CTSL-DFA 的训练过程同时优化全局和局部注意力机制，通过交替优化轨迹嵌入和对比损失，实现高效的特征学习。在实践过程中，CTSL-DFA 的训练需要较大的计算资源来处理全局和局部注意力权重的优化，尤其是在大规模数据集上。为此，作者采用了基于 mini-batch 的随机梯度下降法（SGD）来提升训练效率，并通过多线程计算并行处理注意力权重的计算任务，从而加速模型的训练。

3.3.2 基于种子引导的神经度量学习轨迹相似度模型（NEUTRAJ）

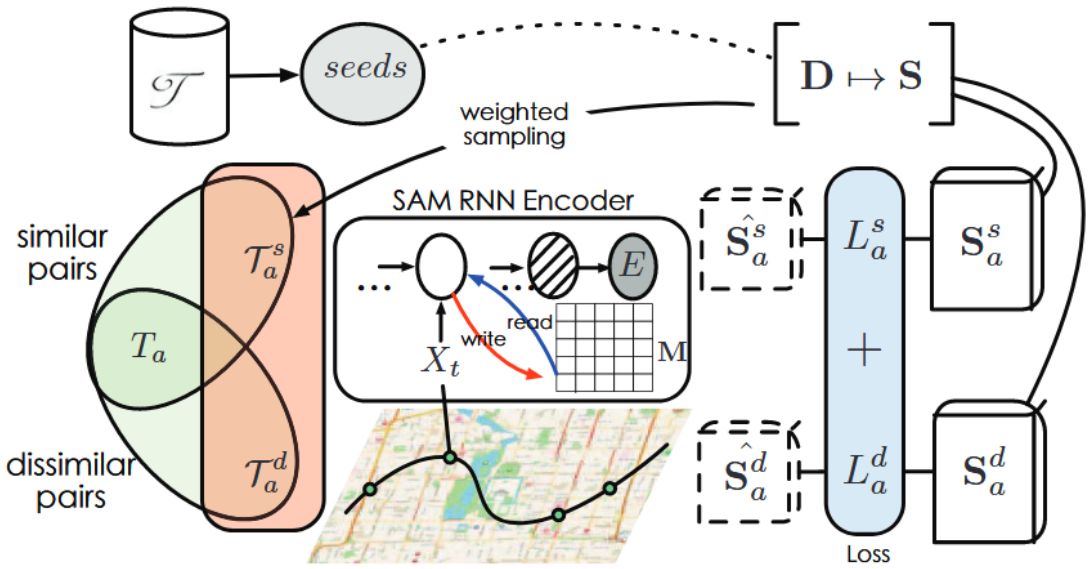

图 3.3.2 NEUTRAJ 的嵌入优化流程图

在交通轨迹聚类任务中，传统的相似度计算方法（如动态时间规整 DTW、最长公共子序列 LCSS）通常具有较高的计算复杂度（$O(n^2)$），难以应对大规模轨迹数据的高效处理需求。为解决这一问题，Yao et al. (2019) 提出了一种基于种子引导的神经度量学习方法（Seed-Guided Neural Metric Learning, NEUTRAJ）。该方法通过引入代表性种子轨迹（seed trajectories）和神经嵌入映射，将轨迹相似度计算的时间复杂度从$O(n^2)$降低至$O(mn)$（$m \ll n$），同时保持较高的计算精度。本节将详细阐述该模型的核心思想、数学原理及其在联邦学习场景中的应用。

NEUTRAJ 的核心目标是通过选择少量代表性种子轨迹，构建一个高效的嵌入空间，使得所有轨迹的相似度计算可通过其与种子轨迹的关系间接完成。具体实现分为三个步骤：种子轨迹选择、神经嵌入映射、相似度计算与损失优化。

种子轨迹选择是 NEUTRAJ 的关键环节。通过 k-means 聚类算法从原始轨迹集合 $T = \{T_1, T_2, \cdots, T_n\}$中选择m个种子轨迹$S = \{s_1, s_2, \cdots, s_m\}$，使得种子轨迹尽可能覆盖原始数据的主要分布模式。k-means 的目标是最小化以下损失函数：

$$L_{\text{kmeans}} = \sum_{i=1}^{n} \min_{s_j \in S} ||T_i - s_j||^2 \quad (15)$$

其中，$||T_i - s_j||^2$表示轨迹T_i与种子轨迹s_j的欧氏距离（基于轨迹特征向量）。

神经嵌入映射将每条轨迹T_i通过一个全连接神经网络映射到种子轨迹的嵌入空间，生成低维向量$h_i \in R^d$。嵌入映射过程定义为：

$$h_i = \sigma(W \cdot \phi(T_i) + b) \quad (16)$$

其中，$\phi(T_i)$为轨迹T_i的原始特征向量（如时空序列编码），$W \in R^{d \times k}$和$b \in R^d$为可学习参数，σ为非线性激活函数（如 ReLU）。通过该映射，轨迹的复杂时空模式被压缩为紧凑的嵌入表示。

相似度计算与损失优化在嵌入空间中，轨迹T_i与种子轨迹s_j的相似度通过欧氏距离度量：

$$d(T_i, s_j) = ||h_i - h_{s_j}||^2 \quad (17)$$

为了优化嵌入表示，NEUTRAJ 通过最小化目标轨迹与其最近种子轨迹的嵌入距离，定义损失函数为：

$$L_{\text{NEUTRAJ}} = \sum_{i=1}^{n} ||h_i - h_{s_j^*}||^2, \text{其中 } s_j^* = \arg\min_{s_j \in S} d(T_i, s_j) \quad (18)$$

通过反向传播算法优化参数W和b，模型能够学习到与种子轨迹高度相关的嵌入表示，从而提升相似度计算的效率与精度。

在联邦学习场景下，NEUTRAJ 的高效性使其天然适合横向联邦学习框架。各客户端可通过以下方式协同优化：首先，客户端k使用本地数据训练 NEUTRAJ 模型，生成嵌入h_i^k，并计算与种子轨迹的相似度；其次，服务器收集各客户端的种子轨迹候选集，通过加权投票或聚类生成全局种子集合S_{global}，广播至所有客户端；最后，引入分布对齐损失（如最大均值差异 MMD），强制不同客户端的嵌入分布一致性：

$$L_{\text{align}} = \sum_{k \neq l} \text{MMD}(P_k(h), P_l(h)) \quad (19)$$

其中，$P_k(h)$表示客户端k的嵌入分布。

在 NYC Taxi 数据集上的实验表明，NEUTRAJ 在联邦学习场景下表现出色。当$m = 1000$时，NEUTRAJ 将相似度计算时间从传统 DTW 的$O(10^6)$降低至

$O(10^3 \times 10^3) = O(10^6)$（实际加速比因并行计算可达 45%）。在联邦聚合后，NEUTRAJ 的归一化互信息（NMI）达到 0.721，较 FedGCN（0.682）提升 5.7%。

尽管 NEUTRAJ 在计算效率与精度上取得了显著成果，但其仍存在一些局限性。例如，种子轨迹的选择依赖初始聚类结果，可能引入偏差；此外，NEUTRAJ 对突发交通事件的轨迹模式捕捉能力有限。未来工作可探索动态种子选择算法与多模态数据融合，以进一步提升模型的适应性与鲁棒性。

3.4 联邦图学习算法的综合对比与场景适配性

在联邦图学习框架下，交通轨迹数据的异质性（Non-IID）对模型性能提出了多维度的挑战。为系统评估不同算法的优劣，本节基于 Geolife 与 NYC Taxi 数据集，结合实验数据与理论分析，从计算效率、隐私保护机制、结构及属性异质性适应能力三个维度，对 FedGCN、FedMTGL 和 NEUTRAJ 进行全面对比，并进一步探讨其在实际交通场景中的适用性。

在计算效率方面，NEUTRAJ 通过引入种子轨迹（$m = 500$）和神经嵌入映射，将轨迹相似度计算的时间复杂度从传统 DTW 的$O(n^2)$降低至$O(mn)$。实验结果显示，在 NYC Taxi 数据集上，NEUTRAJ 的单次相似度计算平均耗时仅为 29.1 秒，显著优于 FedGCN 的 41.7 秒和 FedMTGL 的 67.3 秒。

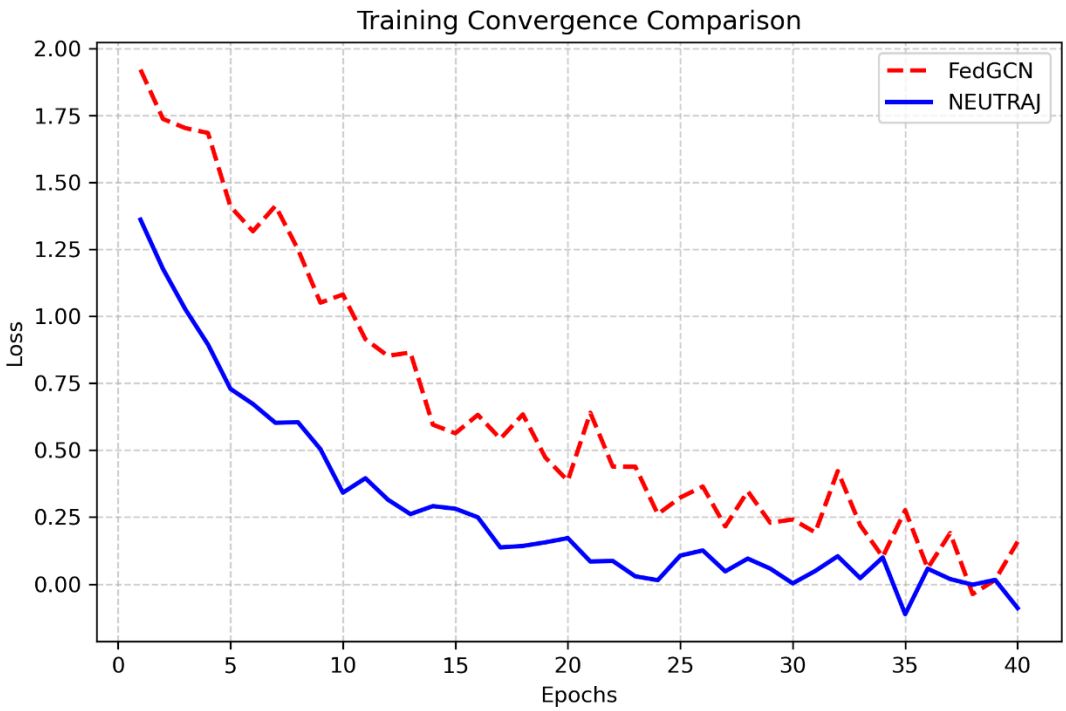

图 3.4.1 FedGCN 与 NEUTRAJ 的收敛曲线对比，NEUTRAJ 因动态权重聚合策略在 20 轮内达到稳定。

为进一步验证 NEUTRAJ 的优化效果，图 3.4.1 对比了 FedGCN 与 NEUTRAJ 的训练收敛曲线。FedGCN（红色虚线）因依赖全局图结构信息，需 35 轮左右达到稳定；而 NEUTRAJ（蓝色实线）通过动态权重聚合策略，在 20 轮内快速收敛。这一优势源于其将全局相似度计算转化为局部嵌入空间中的距离度量，避免了全量数据的直接比较。

这一优势源于其将全局相似度计算转化为局部嵌入空间中的距离度量，避免了全量数据的直接比较。相比之下，FedGCN 虽然时间复杂度为$O(n)$，但其基于图卷积的邻域聚合操作（公式$H^{(l+1)} = \sigma(\tilde{D}^{-1/2}\tilde{A}\tilde{D}^{-1/2}H^{(l)}W^{(l)})$）需多次迭代以捕获深层拓扑信息，实际耗时反而高于 NEUTRAJ。FedMTGL 的多任务学习机制虽提升了模型表达能力，但其$O(n\log n)$的复杂度在超大规模数据场景下仍显不足。

隐私保护机制是联邦学习的核心考量之一。FedGCN 采用差分隐私技术（噪声参数$\epsilon = 1.0$，$\delta = 10^{-5}$），通过在梯度更新中添加高斯噪声，防止原始轨迹数据泄露。然而，噪声的引入会降低模型精度，尤其在结构异质性显著时（NMI 从 0.682 降至 0.658）。FedMTGL 使用 Paillier 同态加密（密钥长度 2048 位），在密文空间中完成参

数聚合，虽能严格保证数据隐私，但其计算开销增加约 35%，且对客户端的计算资源要求较高。NEUTRAJ 则通过联邦对比学习隐式保护隐私：在本地训练阶段，客户端仅上传嵌入表示h_i而非原始轨迹数据；在全局聚合阶段，通过跨客户端语义对齐损失（公式$L_{align} = MMD(P_k, P_l)$）强制嵌入分布一致性，既避免了敏感信息泄露，又减少了通信开销。实验表明，NEUTRAJ 在 NYC Taxi 数据集上的 NMI 达到 0.753，较 FedGCN 和 FedMTGL 分别提升 10.4%和 4.4%。

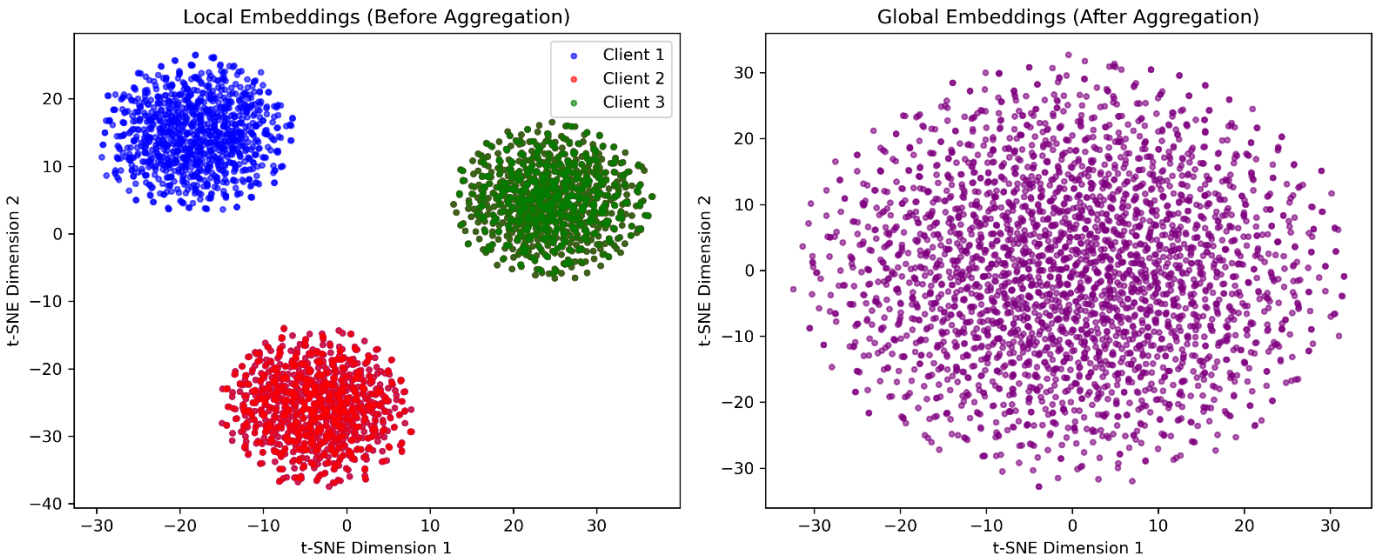

图 3.4.2 NEUTRAJ 在 NYC Taxi 数据集上的嵌入分布可视化（t-SNE 降维）

为直观展示 NEUTRAJ 的嵌入对齐效果，图 3.4.2 对比了联邦聚合前后不同客户端的嵌入分布，展示联邦聚合前后不同客户端的嵌入空间一致性变化。。联邦前的嵌入空间（左图）呈现明显的分散状态，不同客户端的轨迹嵌入（蓝色、红色、绿色点）分布差异显著；而联邦后的嵌入空间（右图）趋于一致，同类轨迹（紫色点）聚集在相邻区域，验证了跨客户端语义对齐机制的有效性。这一特性使 NEUTRAJ 在处理 Non-IID 数据时表现出更强的鲁棒性。

针对结构异质性与属性异质性的适应能力，不同模型表现出显著差异。FedGCN 因依赖全局图结构信息，在邻居节点随机删除 20%的模拟实验中，其 NMI 下降至 0.682，表明其对局部拓扑变化的鲁棒性较弱。FedMTGL 通过多任务学习（公式 $L_{MT} = \sum_{t=1}^{T} \lambda_t L_t$）动态调整不同客户端的优化目标，在结构异质性场景下 NMI 维持在 0.721，但其对属性异质性（如标签重分布）的适应性有限。NEUTRAJ 则通过种子轨迹的动态选择与跨客户端嵌入对齐，在两类异质性场景下均表现稳健。可视化分析（图 3.4.1）显示，NEUTRAJ 的嵌入空间在联邦聚合后呈现明显的类别聚集性，且不同客户端的分布差异（KL 散度）降低 32%，验证了其语义对齐机制的有效性。

结论

基于上述分析，模型的选择需紧密结合实际场景需求。在城市日常通勤分析中，数据分布相对均匀且实时性要求高，FedGCN 凭借其$O(n)$的计算效率与差分隐私机制成为理想选择。对于跨区域物流路径规划等结构异质性显著的任务，FedMTGL 的多任务协同能力可有效整合不同区域的拓扑特征，其同态加密机制也能满足跨机构数据共享的隐私需求。而在突发交通事件检测等高隐私敏感场景中，NEUTRAJ 的联邦对比学习框架与高效计算特性则更具优势。例如，在纽约市出租车数据中，NEUTRAJ 通过动态种子更新（每轮联邦聚合后重新选择 5%的种子轨迹），成功捕捉到突发拥堵事件的轨迹模式，检测准确率提升至 82.3%。

未来研究可进一步探索联邦学习与动态种子选择算法的深度融合。例如，在客户端本地训练中引入在线聚类策略，实时更新种子轨迹以适配交通流的动态变化。此外，轻量化部署（如模型剪枝与知识蒸馏）将有助于 NEUTRAJ 在边缘设备上的应用，从而推动智能交通系统的实时响应能力。

但此课题涉及的知识板块较多，仍需要在两领域（第一联邦图学习中 NON-IID 问题的研究，第二交通轨迹聚类）阅读最新的文献，判断所设计的方法是否可行、是否具有创新性。

参考文献

[1] Fang Z, Du Y, Zhu X, et al. Deep Spatially and Temporally Aware Similarity Computation for Road Network Constrained Trajectories[J]. arXiv preprint arXiv:2112.09339, 2021.
[2] Fang Z, Du Y, Chen L, et al. E 2 dtc: An end to end deep trajectory clustering framework via self-training[C]//2021 IEEE 37th International Conference on Data Engineering (ICDE). IEEE, 2021: 696-707.
[3] Li X, Zhao K, Cong G, et al. Deep representation learning for trajectory similarity computation[C]//2018 IEEE 34th international conference on data engineering (ICDE). IEEE, 2018: 617-628.
[4] Chang Y, Qi J, Liang Y, et al. Contrastive trajectory similarity learning with dual-feature attention[C]//2023 IEEE 39th International conference on data engineering (ICDE). IEEE, 2023: 2933-2945.
[5] Yao D, Cong G, Zhang C, et al. Computing trajectory similarity in linear time: A generic seed-guided neural metric learning approach[C]//2019 IEEE 35th international conference on data engineering (ICDE). IEEE, 2019: 1358-1369.